



最优化技术原理及应用

王冰川

bingcwang@csu.edu.cn

<https://intleo.csu.edu.cn/index.html>

中南大学自动化学院



无约束优化基础

主要参考中国科学院大学Xiao Wang老师PPT
内容

主要内容

1 数学基础

2 最优解

3 代表性算法



主要内容

1 数学基础

2 最优解

3 代表性算法





- 向量: $x \in \mathbb{R}^n, x = (x_1, x_2, \dots, x_n)^T$
- 内积: $x, y \in \mathbb{R}^n, x^T y = \sum_{i=1}^n x_i y_i$
- 矩阵: $A \in \mathbb{R}^{m \times n}$
- 半正定: $A \in \mathbb{R}^{n \times n}, \forall x \in \mathbb{R}^n, x^T A x \geq 0$
- 正定: $A \in \mathbb{R}^{n \times n}, \forall x \in \mathbb{R}^n, x^T A x > 0$
- 正交: $Q \in \mathbb{R}^{n \times n}, Q^T Q = Q Q^T = I$
- 特征值, 特征向量: $Ax = \lambda x$



- l_1 - norm: $\|x\|_1 = \sum_{i=1}^n |x_i|$
- l_2 - norm: $\|x\|_2 = (\sum_{i=1}^n x_i^2)^{1/2} = (x^T x)^{1/2}$
- l_∞ - norm: $\|x\|_\infty = \max_{i=1, \dots, n} |x_i|$
- l_p - norm: $\|x\|_p = (\sum_{i=1}^n |x_i|^p)^{1/p}$
- $\|x\|_\infty \leq \|x\|_2 \leq \sqrt{n} \|x\|_\infty, \|x\|_\infty \leq \|x\|_1 \leq n \|x\|_\infty$
- Cauchy-Schwarz 不等式: $|x^T y| \leq \|x\|_2 \|y\|_2$



- 定义: $A \in \mathbb{R}^{m \times n}, \|A\| = \max_x \frac{\|Ax\|}{\|x\|}$
- $\|A\|_1 = \max_{j=1, \dots, n} \sum_{i=1}^m |A_{ij}|$
- $\|A\|_2 = (A^T A)^{1/2}$ 最大的特征值
- $\|A\|_\infty = \max_{i=1, \dots, m} \sum_{j=1}^n |A_{ij}|$
- *Frobenius* 范数: $\|A\|_F = (\sum_{i=1}^m \sum_{j=1}^n A_{ij}^2)^{1/2}$
- 条件数: $\kappa(A) = \|A\| \|A^{-1}\|$



➤ Frechet 可微: $f: \mathcal{R}^n \rightarrow \mathcal{R}$ 可微的充分条件:

$$\exists g \in \mathcal{R}^n, \lim_{y \rightarrow 0} \frac{f(x+y) - f(x) - g^T y}{\|y\|} = 0$$

➤ 梯度: $g(x) = \nabla f(x) = \left(\frac{\partial f}{\partial x_1}, \frac{\partial f}{\partial x_2}, \dots, \frac{\partial f}{\partial x_n} \right) \in \mathcal{R}^n$

➤ Hessian: $H(x) = \nabla^2 f(x) = \begin{pmatrix} \frac{\partial^2 f}{\partial x_1 \partial x_1} & \cdots & \frac{\partial^2 f}{\partial x_1 \partial x_n} \\ \vdots & \ddots & \vdots \\ \frac{\partial^2 f}{\partial x_n \partial x_1} & \cdots & \frac{\partial^2 f}{\partial x_n \partial x_n} \end{pmatrix}$



➤ 链式法则: $\alpha, \beta \in \mathcal{R}$

$$\frac{d\phi(\alpha(\beta))}{d\beta} = \phi'(\beta)\alpha'(\beta)$$

➤ 链式法则: $x, t \in \mathcal{R}; x = x(t); h(t) = f(x(t))$

$$\nabla h(t) = \sum_{i=1}^n \frac{\partial f}{\partial x_i} \nabla x_i(t) = \nabla x(t)^T \nabla f(x(t))$$

➤ 直接求导: $D(f(x); p) = \lim_{\epsilon \rightarrow 0} \frac{f(x+\epsilon p) - f(x)}{\epsilon} = \nabla f(x)^T p$



$\{x_k\}$ 代表 \mathcal{R}^n 中收敛到 x^* 的一组序列，不同的收敛速率定义如下

➤ **Q-linear**: \forall 充分大的 $k, \exists r \in (0,1)$ 使得下式成立

$$\frac{\|x_{k+1} - x^*\|}{\|x_k - x^*\|} \leq r$$

➤ **Q-superlinear** : $\lim_{k \rightarrow \infty} \frac{\|x_{k+1} - x^*\|}{\|x_k - x^*\|} = 0$

➤ **Q-quadratic**: \forall 充分大的 $k, \exists M$ 使得下式成立

$$\frac{\|x_{k+1} - x^*\|}{\|x_k - x^*\|^2} \leq M$$

主要内容

1 数学基础

2 最优解

3 代表性算法





➤ 一个无约束优化问题定义如下

$$\min_{x \in \mathcal{R}^n} f(x)$$

其中， $f: \mathcal{R}^n \rightarrow \mathcal{R}$ 是一个平滑函数

➤ 一般来说，有关 f 的信息并不容易获得，使用尽量少的信息获得最优值是值得考虑的。



- **全局最优**: x^* 是全局最优解, 如果满足以下条件

$$f(x^*) \leq f(x), \forall x \in \mathcal{R}^n$$

- **局部最优**: x^* 是局部最优解, 如果在其领域 \mathcal{N} 满足以下条件

$$f(x^*) \leq f(x), \forall x \in \mathcal{N}$$

- **严格局部最优**: x^* 是严格局部最优解

$$f(x^*) \leq f(x), \forall x \in \mathcal{N} \text{ with } x \neq x^*$$

- **孤立 (isolated) 局部最优**: x^* 是孤立局部最优解

x^* 是邻域内唯一的局部最优解



最优解


最优性定义



中南大學
CENTRAL SOUTH UNIVERSITY

➤ 一个例子

$$f(x) = x^4 \cos\left(\frac{1}{x}\right) + 2x^4$$





➤ 通过定义判定，如果目标函数 f 是平滑的，则可以根据其一阶导数（梯度向量）、二阶导数（Hessian矩阵）进行判定，主要是利用Taylor's Theorem判定

➤ Taylor's Theorem: 假设 $f: \mathcal{R}^n \rightarrow \mathcal{R}$ 连续可微，并且 $p \in \mathcal{R}^n$,则有

$$f(x + p) = f(x) + \nabla f(x + tp)^T p, \text{ for some } t \in (0,1)$$

如果 f 连续二阶可导，则有

$$\nabla f(x + p) = \nabla f(x) + \int_0^1 \nabla^2 f(x + tp) p dt$$



➤ **Taylor's Theorem**: 假设 $f: \mathcal{R}^n \rightarrow \mathcal{R}$ 连续可微, 并且 $p \in \mathcal{R}^n$, 则有

$$f(x + p) = f(x) + \nabla f(x + tp)^T p, \text{ for some } t \in (0, 1)$$

如果 f 连续二阶可导, 则有

$$\nabla f(x + p) = \nabla f(x) + \int_0^1 \nabla^2 f(x + tp) p dt$$

$$f(x + p) = f(x) + \nabla f(x)^T p + \frac{1}{2} p^T \nabla^2 f(x + tp) p, \\ \text{for some } t \in (0, 1)$$



- **First-Order Necessary Conditions**: 假设 x^* 是 f 的局部最优, f 在 x^* 的一个开邻域内 (D) 连续可微, 则 $\nabla f(x^*) = 0$
- **简要证明**: 反证法证明, 假设 $\nabla f(x^*) \neq 0$, 定义 $p = -\nabla f(x^*)$, 因为 D 为开集合并且 f 连续可微, 那么存在一个足够小的数 t , 使得 $\forall \tau \in [0, t], x^* + \tau p \in D$ 并且 $\nabla f(x^* + \tau p)^T p < 0$, 根据Taylor's Theorem, 存在 $\theta \in (0, t)$ 满足

$$f(x^* + \tau p) < f(x^*) + \tau \nabla f(x^* + \theta p)^T p < f(x^*)$$

这与 $f(x^*)$ 是局部最优矛盾



➤ **Second-Order Necessary Conditions**: 假设 x^* 是 f 的局部最优, f 在 x^* 的一个开邻域内 (D) 连续二阶可微, 则 $\nabla f(x^*) = 0$, $\nabla^2 f(x^*)$ 半正定

➤ **简要证明**: 反证法, 假设 $\nabla^2 f(x^*)$ 不是半正定, 则存在向量 p 使得 $p^T \nabla^2 f(x^*) p < 0$ 。存在一个足够小的数 t , 使得 $\forall \tau \in [0, t], x^* + \tau p \in D$ 并且 $p^T \nabla^2 f(x^* + \tau p) p < 0$, 根据Taylor's Theorem, 存在 $\theta \in (0, t)$ 满足

$$\begin{aligned} f(x^* + \tau p) &< f(x^*) + \nabla f(x^*) \tau p + \tau^2 p^T \nabla^2 f(x^* + \theta p) p \\ &< f(x^*) \end{aligned}$$

这与 $f(x^*)$ 是局部最优矛盾



- 必要条件是假设 x^* 为局部最优的前提下，得出 $\nabla f(x^*)$ 和 $\nabla^2 f(x^*)$ 的相关性质
- 如果 $\nabla f(x^*) = 0$ ，则 x^* 被称为稳定点
- 稳定点不一定是局部最优点 $f(x) = x^3$



➤ **Second-Order Sufficient Conditions:** 假设 $f: D \rightarrow \mathcal{R}$ 二阶可导, $x^* \in D, \nabla f(x^*) = 0, \nabla^2 f(x^*)$ 正定, 则 x^* 是一个严格的局部最优解

➤ **简要证明:** 以 x^* 为中心, 选择一个半径 (r) 充分小的邻域, 对于该邻域内的任意向量 $\|p\| \leq r$, $\nabla^2 f(x^* + tp) > 0$, 根据 Taylor's Theorem, 存在 $t \in (0,1)$, 使得满足

$$\begin{aligned} f(x^* + p) &= f(x^*) + \nabla f(x^*)p + p^T \nabla^2 f(x^* + tp) \\ &> f(x^*) \end{aligned}$$

注意: 严格的局部最优解不一定满足该充分条件!



x^* 是凸优化问题的局部最优, 则对于可行域内的任意一个解 y , 有 $f(y) \geq f(x^*)$:

- 由于局部最优性, $z \in \Omega \cap \aleph, f(z) \geq f(x^*)$;
- 由于可行域的凸性, x 和 y 的连线也在可行域内;
- 在 $\Omega \cap \aleph$ 中的连线上选择一个不等于 x^* 的解: $z = \alpha y + (1 - \alpha)x^*$
- 凸函数性质: $f(z) \leq \alpha f(y) + (1 - \alpha)f(x^*) = f(x^*) + \alpha(f(y) - f(x^*))$
- 因为 $f(z) \geq f(x^*)$, 所以 $\alpha(f(y) - f(x^*)) \geq 0$, 即 $f(y) - f(x^*) \geq 0$

主要内容

1 数学基础

2 最优解

3 代表性算法





- 选择初始点 x_0 ，可根据先验知识选择，亦可任意选择
- 以此为起点，优化算法产生一个序列

$$x_1, x_2, \dots$$

- 当达到某一个终止条件时，算法停止

- 如何产生解序列是一个优化算法的重点
- 终止条件包括解没有改进，或者迭代次数达到给定值等等



算法使用有关 x_k 处函数 f 的信息，也可能使用来自早期迭代的信息，决定如何从 x_k 移动到 x_{k+1}

- **单调算法**：找到函数值低于 x_k 的新迭代 x_{k+1}
- **非单调算法**：不坚持每一步都减小 f ，而是要求 f 在规定的 m 次迭代后减小，即 $f(x_k) < f(x_{k+m})$

从当前点 x_k 移动到新的迭代 x_{k+1} 有两种代表策略：**线搜索**和**信赖域方法**



- 选择方向向量： p_k
- 从当前迭代 x_k 开始沿此方向搜索具有较低函数值的新迭代

$$x_{k+1} \leftarrow x_k + \alpha_k p_k, \quad f(x_k) > f(x_{k+1})$$

- 在新迭代点，计算新的方向（ p_{k+1} ）和步长（ α_{k+1} ），并重复以上过程达到终止条件



- 如何确定搜索步长 α_k ?
- 当搜索方向 p_k 确定以后，可以通过最小化以下问题来确定 α_k

$$\alpha_k = \min_{\alpha > 0} f(x_k + \alpha p_k)$$

- 一般来说，有两种方法设定 α_k
 - 直接求解以上问题，但是优化过程将添加额外的开销，而且没有必要
 - 线搜索算法可以生成有限数量的试验步长，直到找到一个近似最小步长的 α_k



信赖域方法关键步骤如下：

- 利用有关 f 的信息构建模型函数（model function） m_k ，使其在 x_k 附近与 f 相近
- 但是当 x 远离 x_k 时，模型 m_k 可能不能很好地对 f 近似，因此需要将基于 m_k 的搜索限制在 x_k 周围的信赖域（trust region）内

信赖域方法通过求解以下问题得到搜索方向：

$$p_k = \min_p m_k(x_k + p), x_k + p \text{ 在信赖域内}$$

如果 f 不能充分下降，则对信赖域进行收缩



➤ 通常信赖域定义为半径大小为 σ 的球体： $\|p\| \leq \sigma$ ；也可以使用椭球体和超立方体等定义信赖域

➤ 模型函数 m_k 通常定义为二次函数

$$m_k(x_k + p) = f_k + p^T \nabla f_k + \frac{1}{2} p^T B_k p$$

➤ m_k 和 f 在 x_k 处的一阶导数相同， B_k 一般为Hessian矩阵或者其近似



线搜索策略和信赖域策略的区别在于如何确定搜索方向和搜索步长

- 线搜索策略先确定搜索方向 p_k ，在此基础上确定搜索步长 α_k
- 信赖域策略先确定信赖域大小（对搜索步长进行了限制），在此基础上确定搜索方向
- 后续章节会对两种搜索策略进行详细介绍

Thanks for the attentions!

Q&A