



中南大學
CENTRAL SOUTH UNIVERSITY



最优化技术原理及应用

王冰川

bingcwang@csu.edu.cn

<https://intleo.csu.edu.cn/index.html>

中南大学自动化学院



约束优化基础

主要参考中国科学院大学Xiao Wang老师PPT
内容

主要内容

1 介绍

2 约束规范性条件

3 一阶最优条件

4 对偶

5 参考资料



主要内容

1 介绍

2 约束规范性条件

3 一阶最优条件

4 对偶

5 参考资料





➤ 约束优化问题的通常描述如下

$$\begin{aligned} & \min_{x \in \mathcal{R}^n} f(x) \\ & \text{s.t. } c_i(x) = 0, i \in \mathcal{E}, \\ & \quad c_i(x) \geq 0, i \in \mathcal{I} \end{aligned}$$

➤ $f(x)$ 代表目标函数， $c_i(x)$ 代表约束条件，都是平滑的实值函数； \mathcal{R}^n 是定义域，也就是搜索空间； \mathcal{E} 和 \mathcal{I} 是两个有限索引集合； $c_i(x), i \in \mathcal{E}$ 和 $c_i(x), i \in \mathcal{I}$ 分别代表等式约束和不等式约束



➤ 满足约束条件的点的集合，也就是可行集合 Ω 定义如下

$$\Omega = \{x | c_i(x) = 0, i \in \mathcal{E}; c_i(x) \geq 0, i \in \mathcal{I} \}$$

➤ 因此，原约束优化问题可以表示如下

$$\min_{x \in \Omega} f(x)$$



- 如果 $x^* \in \Omega$ 并且存在邻域 \mathcal{N} , 使得下述条件成立, 则 x^* 是约束优化问题的一个局部最优解

$$f(x^*) \leq f(x), \forall x \in \Omega \cap \mathcal{N}$$

- 如果 $x^* \in \Omega$ 并且存在邻域 \mathcal{N} , 使得下述条件成立, 则 x^* 是约束优化问题的一个严格局部最优解

$$f(x^*) < f(x), \forall x \in \Omega \cap \mathcal{N}$$

- 如果 x^* 是 $\Omega \cap \mathcal{N}$ 中唯一的最优解, 则 x^* 被称作孤立的局部最优解



➤ 平滑性能够保证目标函数和约束具有合理可预测的特性，从而算法可以更好地选择搜索方向

➤ 非光滑边界通常可以通过光滑约束函数的集合描述

$$\|x\|_1 = |x_1| + |x_2| \leq 1$$

$$\Leftrightarrow x_1 + x_2 \leq 1, x_1 - x_2 \leq 1, x_2 - x_1 \leq 1, -x_1 - x_2 \leq 1$$

➤ 非光滑、无约束优化问题有时可以重新表述为光滑约束问题

$$\min f(x) = \max(x^2, x),$$

$$\Leftrightarrow \min t, \quad s.t. \quad t \geq x, t \geq x^2$$



- 可行解 x 处的有效集 $\mathcal{A}(x)$ 由等式约束索引，和满足 $c_i(x) = 0$ 的不等式约束索引组成

$$\mathcal{A}(x) = \mathcal{E} \cup \{i \in \mathcal{I} | c_i(x) = 0\}$$

- 可行解 x 处，如果 $c_i(x) = 0$ ，则不等式约束 $i \in \mathcal{I}$ 被称 active；如果满足 $c_i(x) > 0$ ，则称之为inactive
- 接下来通过几个例子定性说明局部最优解所需要满足的一些条件




介绍

例子：单个等式约束



中南大學
CENTRAL SOUTH UNIVERSITY

$$\min x_1 + x_2 \quad s.t. \quad x_1^2 + x_2^2 - 2 = 0$$





- 为了保持约束的可行性 $c_1(x) = 0$ ，任何小的（但非零）步长 s 需要满足 $c_1(x + s) = 0$ ：

$$0 = c_1(x + s) \approx c_1(x) + \nabla c_1(x)^T s = \nabla c_1(x)^T s$$

- 如果 s 能够导致 f 减小，需要满足：

$$0 > f(x + s) - f(x) \approx \nabla f(x)^T s$$

- 只有当满足如下条件的方向向量 s 不存在时， x^* 是一个局部最优解：

$$\nabla c_1(x^*)^T s = 0 \text{ and } \nabla f(x^*)^T s < 0$$




介绍

例子：单个等式约束



中南大學
CENTRAL SOUTH UNIVERSITY



➤ 形式化理解，只有当 $\nabla f(x^*)$ 和 $\nabla c_1(x^*)$ 平行时，上述条件才成立，也就是在 x^* 处满足：

$$\nabla f(x) = \lambda \nabla c_1(x)$$



➤ 拉格朗日函数：

$$\mathcal{L}(x, \lambda) = f(x) - \lambda c_1(x)$$

➤ $\nabla f(x) = \lambda \nabla c_1(x) \iff \nabla_x \mathcal{L}(x, \lambda) = 0$ ，此处 λ 也被称作拉格朗日乘子

➤ 上述观察结果表明，可以通过搜索拉格朗日函数的稳定点来搜索等式约束问题的解

➤ 这是一个必要条件！




介绍

例子：单个不等式约束



中南大學
CENTRAL SOUTH UNIVERSITY

$$\min x_1 + x_2 \quad \text{s.t.} \quad 2 - x_1^2 - x_2^2 \geq 0$$





- 和之前一样，如果能够找到既保留可行性又将使目标函数 f 下降的方向，则给定的可行解不是极值点
- 如果 s 能够导致 f 减小，需要满足：

$$f(x)^T s < 0$$

- 如果能够保持可行性，需要满足：

$$0 \leq c_1(x + s) \approx c_1(x) + \nabla c_1(x)^T s$$


$$c_1(x) + \nabla c_1(x)^T s \geq 0$$



- **Case I:** x 在圆内，也就是 $c_1(x) > 0$ ，此时当步长足够小的时候，就能保持可行性；当 $\nabla f(x) \neq 0$ 时，可以设置 α 充分小，使得同时满足可行性和下降条件：

$$s = -\alpha \nabla f(x)$$


- 也就是说，当 $\nabla f(x) = 0$ 时，不能同时满足两个条件





- **Case II:** x 在圆上，也就是 $c_1(x) = 0$ ，能够使得两个条件满足的区域如下图所示。也就是说，当 $\nabla f(x)$ 和 $c_1(x)$ 同方向时，不能同时保持可行性和目标函数下降两个条件：

$$\nabla f(x) = \lambda c_1(x), \lambda \geq 0$$





➤ 同样，总结上述两种情况，并通过拉格朗日形式表示：

$$\nabla_x \mathcal{L}(x, \lambda) = 0, \quad \lambda \geq 0$$

$$\lambda c_1(x) = 0$$

➤ 对于 case I, $c_1(x) > 0$, 所以 $\lambda = 0$, 因此以上条件变成了 $\nabla f(x) = 0$;

➤ 对于 case II, $\lambda \geq 0$, 因此以上条件变成 $\nabla f(x) = \lambda c_1(x)$, $\lambda \geq 0$




介绍

例子：两个不等式约束



中南大學
CENTRAL SOUTH UNIVERSITY


$$\min x_1 + x_2 \quad s.t. \quad 2 - x_1^2 - x_2^2 \geq 0, x_2 \geq 0$$



$(-\sqrt{2}, 0)$ 处目标函数和约束条件的梯度方向



- 从下图可以看出，没有方向向量 s 能够对 $(-\sqrt{2}, 0)$ 改进，因此其是一个局部最优解





- 同样，在 $x^* = (-\sqrt{2}, 0)$ 处能够找到满足拉格朗日条件的值

$$\mathcal{L}(x, \lambda) = f(x) - \lambda_1 c_1(x) - \lambda_2 c_2(x)$$

$$\nabla_x \mathcal{L}(x^*, \lambda^*) = 0, \lambda_1 c_1(x^*) = 0, \lambda_2 c_2(x^*) = 0$$

- $\lambda^* = [\frac{1}{2\sqrt{2}}, 1]$ 是满足上述条件的值

- 请同学们自己检验 $(\sqrt{2}, 0)$ 处能否找到满足拉格朗日条件的 λ 值




介绍

例子：两个不等式约束



中南大學
CENTRAL SOUTH UNIVERSITY

➤ 请同学们自己检验 $(\sqrt{2}, 0)$ 处能否找到满足拉格朗日条件的 λ 值



主要内容

1 介绍

2 约束规范性条件

3 一阶最优条件

4 对偶

5 参考资料





- 以上例子通过检查 f 和 c_i 的一阶导数来确定是否可以从给定的可行解 x 采取可行的下降步骤
- 具体来说，利用 f 和 c_i 在 x 处的一阶泰勒级数展开得到一个目标和约束都是线性的近似问题
- 然而，只有当线性近似捕获了相关点 x 附近可行集的基本几何特征时，这种方法才有意义



- 如果在 x 附近，线性化与可行集根本不同，那么线性近似能不能产生有关原始问题的有用信息

$$x^2 = 0$$

在 $x = 0$ 处，线性化对应于整个空间，而可行集是单个点

- 因此，需要对在 x 处active的约束 c_i 的性质做出合理假设，以确保线性化近似与 x 附近的可行集相似
- **约束规范化**是确保约束集 Ω 与其线性化近似在 x 邻域中保持相似所作出的假设



- 给定可行解 x ，有效约束集 \mathcal{A} ，线性化可行方向 $\mathcal{F}(x)$ 定义如下：

$$\mathcal{F}(x) = \left\{ d \left| \begin{array}{l} d^T c_i(x) = 0, \forall i \in \mathcal{E} \\ d^T c_i(x) \geq 0, \forall i \in \mathcal{I} \cap \mathcal{A}(x) \end{array} \right. \right\}$$

- 线性化可行方向集取决于约束函数 $c_i(x), i \in \mathcal{E} \cup \mathcal{I}$ 的定义

- $2 - x_1^2 + x_2^2 = 0$ 和 $(2 - x_1^2 + x_2^2)^2 = 0$ （两种定义）




- 给定可行解 x ，如果 $\{z_k\} \in \Omega$ 并且对于所有足够大的 k 满足 $z_k \rightarrow x$ ，则 $\{z_k\}$ 被称作逼近 x 的可行序列
- 如果向量 d 是可行序列 $\{z_k\}$ 的极限方向，则称向量 d 在点 x 处与 Ω 相切。也就是说，存在一个接近 x 的可行序列 $\{z_k\}$ 和一个正数序列 $\{t_k\}$ ， $z_k \rightarrow 0$ ，满足如下条件

$$\lim_{k \rightarrow \infty} \frac{z_k - x}{t_k} = d$$

- Ω 在 x 处的所有切向量的集合称为切锥： $T_{\Omega}(x)$
- 切锥的定义不依赖于 Ω 的代数形式，仅依赖于其几何形状



$$\min x_1 + x_2 \quad \text{s.t.} \quad x_1^2 + x_2^2 - 2 = 0$$



➤ $x = (-\sqrt{2}, 0)^T$

➤ $z_k = [-\sqrt{2 - 1/k^2} \quad -1/k], t_k = \|z_k - x\| \Rightarrow t = (0, -1)^T$

➤ $z_k = [-\sqrt{2 - 1/k^2} \quad 1/k], t_k = \|z_k - x\| \Rightarrow t = (0, 1)^T$

➤ $T_\Omega(x) = \mathcal{F}(x) = \{(0, d_2)^T | d_2 \in \mathbb{R}\}$



➤ 如果可行域定义形式如下：

$$\Omega = \{x | (x_1^2 + x_2^2 - 2)^2 = 0\}$$

➤ 该可行域不变，但是代数描述形式变了，在此基础上计算 $\mathcal{F}(x)$

$$0 = d^T c(x) = \begin{bmatrix} d_1 \\ d_2 \end{bmatrix}^T \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

此时， $T_\Omega(x) \neq \mathcal{F}(x) = \mathbb{R}^2$

➤ 说明线性化可行方向依赖于代数描述形式



- 约束规范性条件是线性化可行集 $\mathcal{F}(x)$ 与切锥 $T_{\Omega}(x)$ 相似的前提条件
- 事实上，大多数规范性条件能够确保这两个集合是相同的
- 这些条件确保线性化 Ω 代数描述所得到的集合 $\mathcal{F}(x)$ 能够捕获 x 处的几何特征 $T_{\Omega}(x)$



➤ LICQ (Linear Independent Constraint Qualification): 给定解 x 和有效集 $\mathcal{A}(x)$, LICQ条件如下:

有效约束集梯度 $\{\nabla c_i(x), i \in \mathcal{A}(x)\}$ 线性独立

➤ 通常情况下, 当LICQ成立时, 则所有active约束梯度都不能为零

主要内容

1 介绍

2 约束规范性条件

3 一阶最优条件

4 对偶

5 参考资料





➤ 定义拉格朗日函数如下：

$$\mathcal{L}(x, \lambda) = f(x) - \sum_{i \in \mathcal{E} \cup \mathcal{I}} \lambda_i c_i(x)$$

➤ 假设 x^* 是一个局部最优解并且满足LICQ条件，则存在拉格朗日乘子 $\lambda^* = \{\lambda_i^*\}, i \in \mathcal{E} \cup \mathcal{I}$ 使得如下条件在 (x^*, λ^*) 处成立

$$\nabla_x \mathcal{L}(x^*, \lambda^*) = 0,$$

$$c_i(x^*) = 0, \forall i \in \mathcal{E},$$

$$c_i(x^*) \geq 0, \forall i \in \mathcal{I},$$

$$\lambda_i^* \geq 0,$$

$$\lambda_i^* c_i(x^*) = 0, \forall i \in \mathcal{E} \cup \mathcal{I}$$


➤ 以上被称作Karush-Kuhn-Tucker (KKT)条件



- 给定局部最优解 x^* 和满足KKT条件的 λ^* ，如果对于每个不等式约束 $i \in \mathcal{I}$ ， $c_i(x^*)$ 和 λ_i^* 刚好只有一个等于0，则**严格互补条件**成立；换句话说，对于 $i \in \mathcal{I} \cap \mathcal{A}(x^*)$ ， $\lambda_i^* > 0$
- 一般来说，满足严格互补条件可以使得算法更容易确定有效集 $\mathcal{A}(x^*)$ ，并快速收敛到解 x^*
- 对于给定问题和解局部最优解 x^* ，可能有许多向量 λ^* 满足KKT条件；然而，满足**LICQ条件**的 λ^* 是唯一的



$$\min_x (x_1 - 1.5)^2 + (x_2 - 0.5)^4 \quad s. t. \quad \begin{bmatrix} 1 - x_1 - x_2 \\ 1 - x_1 + x_2 \\ 1 + x_1 - x_2 \\ 1 + x_1 + x_2 \end{bmatrix} \geq 0$$





$$\min_x (x_1 - 1.5)^2 + (x_2 - 0.5)^4 \quad s. t. \quad \begin{bmatrix} 1 - x_1 - x_2 \\ 1 - x_1 + x_2 \\ 1 + x_1 - x_2 \\ 1 + x_1 + x_2 \end{bmatrix} \geq 0$$

➤ 一个最优解 $x^* = (1, 0)^T$ ，前两个约束条件 active，而后两个约束条件 inactive，因此有

$$\lambda_3^* = \lambda_4^* = 0$$

➤ 因为有

$$\nabla f(x^*) = \begin{bmatrix} -1 \\ -0.5 \end{bmatrix}, \nabla c_1(x^*) = \begin{bmatrix} -1 \\ -1 \end{bmatrix}, \nabla c_2(x^*) = \begin{bmatrix} -1 \\ 1 \end{bmatrix}$$

➤ 所以 $\lambda_1^* = 0.75, \lambda_2^* = 0.25$

主要内容

1 介绍

2 约束规范性条件

3 一阶最优条件

4 对偶

5 参考资料





- 基于对偶理论提出了包括增广拉格朗日在内的很多重要算法
- 就其一般性而言，对偶理论不但对非线性规划很重要，也为凸非光滑优化，甚至是离散优化提供了重要的工具
- 对偶理论展示了如何根据原始优化问题构造相应的替代问题
- 在某些情况下，对偶问题比原始问题更容易计算；在一些情况下，对偶可轻松获得原始问题最优值的下界



➤ 考虑如下约束优化问题（原问题）

$$\min_{x \in \mathbb{R}^n} f(x), s. t. c(x) \geq 0$$

其中， $c(x) = [c_1(x), c_2(x), \dots, c_m(x)]^T$ ，并且 f 和 $-c_i$ 都是凸函数

➤ 上述问题的对偶问题定义如下：

$$\max_{\lambda \in \mathbb{R}^m} q(\lambda), s. t. \lambda \geq 0$$

其中， $q(\lambda) \equiv \inf_x \mathcal{L}(x, \lambda)$



➤ 考虑如下约束优化问题（原问题）

$$\min_{(x_1, x_2)} 0.5(x_1^2 + x_2^2), s. t. x_1 - 1 \geq 0$$

➤ 其拉格朗日函数如下：

$$\mathcal{L}(x, \lambda) = 0.5(x_1^2 + x_2^2) - \lambda(x_1 - 1)$$

➤ 因为 f 和 c 都是凸函数，当满足如下条件时，取到 \inf_x

$$x_1 - \lambda = 0, x_2 = 0$$

➤ 因此有对偶问题

$$\max_{\lambda \geq 0} -0.5\lambda^2 + \lambda$$



- 在许多问题中，某些 λ 值的下确界为 $-\infty$ ； $q(\lambda)$ 的定义域是使得其为有限值的 λ 集合：

$$\mathcal{D} \equiv \{\lambda | q(\lambda) > -\infty\}$$

- 计算下确界需要找到 $\mathcal{L}(x, \lambda)$ 的全局极小值；在实践中，对于一些 λ ，这可能可能极其困难
- 当 f 和 $-c_i$ 都是凸函数，并且 $\lambda \geq 0$ 时， $\mathcal{L}(\cdot, \lambda)$ 也是凸函数，因此 $q(\lambda)$ 的计算更有效



- $q(\lambda)$ 是凹函数，其定义域 \mathcal{D} 是凸集合
- 对于原问题任意一个可行解 \bar{x} 和 $\bar{\lambda} \geq 0$ ，有 $q(\bar{\lambda}) \leq f(\bar{x})$
- 弱对偶定理是天然成立的，不需要其他前提



$$\min_{x \in \mathbb{R}^n} f(x), s. t. c(x) \geq 0$$

➤ 回顾一下该问题的KKT条件

$$\nabla f(\bar{x}) - \nabla c(\bar{x})\bar{\lambda} = 0$$

$$c(\bar{x}) \geq 0$$

$$\bar{\lambda} \geq 0$$

$$\bar{\lambda}_i c_i(\bar{x}) = 0, i = 1, \dots, m$$

➤ 其中, $\nabla c(\bar{x}) = [\nabla c_1(\bar{x}), \nabla c_2(\bar{x}), \dots, \nabla c_m(\bar{x})]$



- \bar{x} 是原问题的一个解, f 和 $-c_i$ 都是凸函数并且可微, 使得 $(\bar{x}, \bar{\lambda})$ 满足KKT条件的任意 $\bar{\lambda}$ 是对偶问题的解
- 假设 f 和 $-c_i$ 都是凸函数并且连续可微, \bar{x} 是原问题的一个解, 并且满足LICQ条件; 假设 $\hat{\lambda}$ 是对偶问题的一个解并且 $\inf_x \mathcal{L}(x, \hat{\lambda})$ 的下确界在 \hat{x} 处取到, 进一步假设 $\mathcal{L}(\cdot, \hat{\lambda})$ 是一个严格凸函数, 有 $\bar{x} = \hat{x}$ (\hat{x} 是原问题唯一解), $f(\bar{x}) = \mathcal{L}(\bar{x}, \hat{\lambda})$



$$\max_{\lambda, x} \mathcal{L}(x, \lambda), \quad s. t. \nabla_x \mathcal{L}(x, \lambda) = 0, \lambda \geq 0$$

- 假设 f 和 $-c_i$ 都是凸函数并且连续可微, $(\bar{x}, \bar{\lambda})$ 是原问题的解组合, 并且满足LICQ条件, 则 $(\bar{x}, \bar{\lambda})$ 是 Wolfe对偶问题的解



➤ 推导如下二次规划问题的对偶问题和Wolfe对偶问题：

$$\min_{x \in \mathbb{R}^n} \frac{1}{2} x^T G x + c^T x, s. t. Ax - b \geq 0$$

Thanks for the attentions!

Q&A