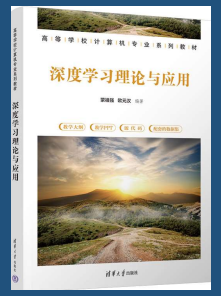

深度学习理论与应用

Deep Learning Theory and Applications

蒙祖强，欧元汉 编著

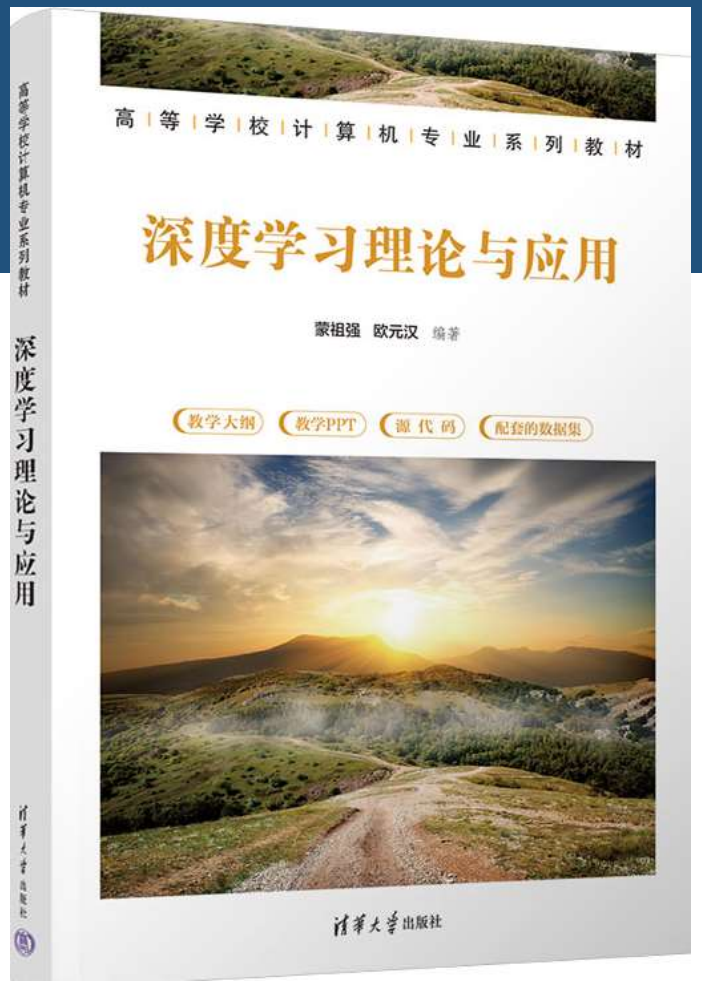

教　材

全国各大书店网店均有销售

- **教学大纲**：提供面向教育工程认证的教学大纲
- **教学PPT**：提供课堂教学用的PPT课件
- **源代码**：提供教材涉及的全部源代码
- **数据集**：提供教材示例、案例用到的全部数据集

获取教学资源：
http://www.tup.tsinghua.edu.cn/booksCenter/book_09988101.html

教材： 蒙祖强，欧元汉 编著. 深度学习理论与应用. 北京: 清华大学出版社，2023年7月. (书号: 978-7-302-63508-6)

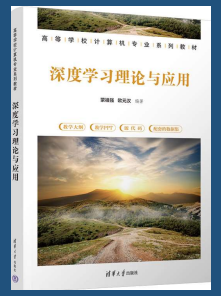

第 5 章 若干经典 CNN 预训练模型及其迁移方法

蒙祖强，欧元汉 编著. 深度学习理论与应用. 北京: 清华大学出版社，2023年7月.

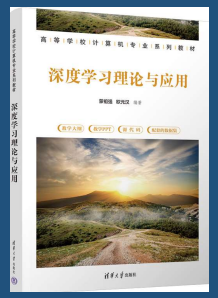

本章内容

contents

5.1 一个使用 VGG16 的图像识别程序

5.2 经典卷积神经网络的结构

5.3 预训练模型的迁移方法

5.1 一个使用 VGG16 的图像识别程序

5.1.1 程序代码

【例5.1】创建一个能够识别猫狗图像的深度神经网络。

- 任务跟例 4.3 的任务一样，都是识别猫和狗的图像。不同的是，本例使用了预训练模型——VGG16，这样使用的训练数据就相对少得多。

- 训练图像位于./data/catdog/training_set2 目录下，猫和狗的图像各 1000 张，一共有 2000 张图像作为训练数据，它们都是从./data/catdog/training_set 目录中随机抽取，但测试集不变（跟例 4.3 一样，位于./data/catdog/test_set 目录下，一共有 2023 张）。

5.1 一个使用 VGG16 的图像识别程序

5.1.1 程序代码

本程序首先导入 VGG16，然后冻结参数并修改模型的部分结构，以适合本例的任务。

最后进行训练和测试。程序的核心代码如右：

```
start=time.time() #开始计时
cat_dog_vgg16.train()
for epoch in range(10): #执行  10 代
        ep_loss=0
                for i,(x,y) in enumerate(train_loader):
                x, y = x.to(device),y.to(device)
                pre_y = cat_dog_vgg16(x)
                loss = nn.CrossEntropyLoss()(pre_y, y.long()) # 使用交叉熵损失函数
                ep_loss += loss*x.size(0) #loss 是损失函数的平均值,故要乘以样本数量
                optimizer.zero_grad()
                loss.backward()
                optimizer.step()
                print('第 %d 轮循环中，损失函数的平均值为: %.4f'\
                %(epoch+1,(ep_loss/len(train_loader.dataset))))
end = time.time() #计时结束
print('训练时间为: %.1f 秒 '%(end-start))
```

该程序的核心代码（全部代码见教材P120）

5.1 一个使用 VGG16 的图像识别程序

5.1.1 程序代码

执行上述代码后，结果如下（部分）：

```
… …
第 9 轮循环中，损失函数的平均值为: 0.0460
第 10 轮循环中，损失函数的平均值为: 0.0553
训练时间为:  86.4 秒
1. 网络模型在训练集上的准确率：99.70%
2. 网络模型在测试集上的准确率：96.69%
```

与例 4.3 相比，该程序的训练数据少了，运行的代数少了，但准确率却大幅度上升。显然，这得益于预训练模型 VGG16 的功劳，是站在 VGG16 这个“巨人肩膀”上的结果。

5.1 一个使用 VGG16 的图像识别程序

5.1.2 代码解释

本例主要是导入了一个预训练模型——VGG16，创建实例 cat_dog_vgg16，以代替在例 4.3 中创建的实例 model_CatDog，其他部分代码基本相同。相关代码说明如下：

（1）通过下面语句从模型库 models 中导入已经训练好的模型 VGG16：

```
cat_dog_vgg16 = models.vgg16(pretrained=True)
```

其中，pretrained=True 表示要下载已训练好的所有参数。如果 pretrained=False，则表示不下载这些参数，而使用随机方法初始化所有参数。这相当于只使用模型 VGG16 的结构，而不要其训练过的参数。显然，一般情况下使用 pretrained=True。

5.1 一个使用 VGG16 的图像识别程序

5.1.2 代码解释

如果向导入 VGGNET 的另一个家族成员——VGG19，则用下列语句即可：

```
cat_dog_vgg19 = models.vgg19(pretrained=True)
```

注意，此处的 cat_dog_vgg16 就是相当于例 4.3 中的 model_CatDog，都是已经创建好的实例。因此，在本例中可以不再创建一个类了。

5.1 一个使用 VGG16 的图像识别程序

5.1.2 代码解释

（2）使用下列语句冻结刚创建的模型 vgg16 的参数：

```
for i,param in enumerate(cat_dog_vgg16.parameters()):
    param.requires_grad = False #冻结 cat_dog_vgg16 的所有参数
```

如果一个参数的 requires_grad 属性值设置为 False，则该参数在训练过程中是不能被更新的，因而称为“冻结”。由于 VGG16 中的参数都是训练过的，已被实践证明是可行的，因 而在后面的训练过程中就不需要再训练了，而且 VGG16 中的参数量巨大，一般也没有条件 来训练它们。

5.1 一个使用 VGG16 的图像识别程序

5.1.2 代码解释

用下列代码，可以查看模型中各层参数张量是否可以被训练：

```
for layer in cat_dog_vgg16.named_modules():
    t = list(layer[1].parameters())
    if len(t) == 0: #如果当前层没有训练参数，则 len(t) = 0
        continue
    L = []
    for param in layer[1].parameters():
        L.append(param.requires_grad)
    print(layer[0], ' ----------> ',L) #True 表示相应参数张量可训练，False 表示不可以
```

5.1 一个使用 VGG16 的图像识别程序

5.1.2 代码解释

（3）对模型 cat_dog_vgg16 进行微调，改为适合本例识别任务的网络结构。先用下列语句打印出 cat_dog_vgg16 的层次结构：

```
print(cat_dog_vgg16)
```

结果如图所示（下页）。从图中可以看出，该网络有 1000 个输出，而本程序只需要两个输出，因而至少需要更改最后一层网络的输出结构。作为例子，本例修改最后面的两个全 连接层，即修改下面这两层：

```
(3): Linear(in_features=4096, out_features=4096, bias=True)
(6): Linear(in_features=4096, out_features=1000, bias=True)
```

5.1 一个使用 VGG16 的图像识别程序

5.1.2 代码解释

修改后VGG结构如右图所示：

```
VGG(
(features): Sequential(
    (0): Conv2d(3, 64, kernel_size=(3, 3), stride=(1, 1), padding=(1, 1))
    (1): ReLU(inplace=True)
    (2): Conv2d(64, 64, kernel_size=(3, 3), stride=(1, 1), padding=(1, 1))
    (3): ReLU(inplace=True)
    (4): MaxPool2d(kernel_size=2, stride=2, padding=0, dilation=1, ceil_mode=False)
    (5): Conv2d(64, 128, kernel_size=(3, 3), stride=(1, 1), padding=(1, 1))
    (6): ReLU(inplace=True)
    (7): Conv2d(128, 128, kernel_size=(3, 3), stride=(1, 1), padding=(1, 1))
    (8): ReLU(inplace=True)
    (9): MaxPool2d(kernel_size=2, stride=2, padding=0, dilation=1, ceil_mode=False)
    (10): Conv2d(128, 256, kernel_size=(3, 3), stride=(1, 1), padding=(1, 1))
    (11): ReLU(inplace=True)
    (12): Conv2d(256, 256, kernel_size=(3, 3), stride=(1, 1), padding=(1, 1))
    (13): ReLU(inplace=True)
    (14): Conv2d(256, 256, kernel_size=(3, 3), stride=(1, 1), padding=(1, 1))
    (15): ReLU(inplace=True)
    (16): MaxPool2d(kernel_size=2, stride=2, padding=0, dilation=1, ceil_mode=False)
    (17): Conv2d(256, 512, kernel_size=(3, 3), stride=(1, 1), padding=(1, 1))
    (18): ReLU(inplace=True)
    (19): Conv2d(512, 512, kernel_size=(3, 3), stride=(1, 1), padding=(1, 1))
    (20): ReLU(inplace=True)
    (21): Conv2d(512, 512, kernel_size=(3, 3), stride=(1, 1), padding=(1, 1))
    (22): ReLU(inplace=True)
    (23): MaxPool2d(kernel_size=2, stride=2, padding=0, dilation=1, ceil_mode=False)
    (24): Conv2d(512, 512, kernel_size=(3, 3), stride=(1, 1), padding=(1, 1))
    (25): ReLU(inplace=True)
    (26): MaxPool2d(kernel_size=2, stride=2, padding=0, dilation=1, ceil_mode=False)
    (27): Conv2d(512, 512, kernel_size=(3, 3), stride=(1, 1), padding=(1, 1))
    (28): ReLU(inplace=True)
    (29): Conv2d(512, 512, kernel_size=(3, 3), stride=(1, 1), padding=(1, 1))
    (30): ReLU(inplace=True)
    (31): Conv2d(512, 512, kernel_size=(3, 3), stride=(1, 1), padding=(1, 1))
    (32): ReLU(inplace=True)
    (33): MaxPool2d(kernel_size=2, stride=2, padding=0, dilation=1, ceil_mode=False)
)
(avgpool): AdaptiveAvgPool2d(output_size=(7, 7))
(classifier): Sequential(
    (0): Linear(in_features=25088, out_features=4096, bias=True)
    (1): ReLU(inplace=True)
    (2): Dropout(p=0.5, inplace=False)
    (3): Linear(in_features=4096, out_features=4096, bias=True)
    (4): ReLU(inplace=True)
    (5): Dropout(p=0.5, inplace=False)
    (6): Linear(in_features=4096, out_features=1000, bias=True)
    )
)
```

VGG16 结构的层次图

5.1 一个使用 VGG16 的图像识别程序

5.1.2 代码解释

（4）在加载数据时，以./data/catdog/training_set2 目录下的图像文件作为训练数据，训练的代数改为 10 代。除了上述改变外，数据加载方法、模型训练方法和测试方法等其他部 分跟例 4.3 的相同。

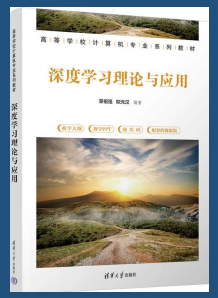

本章内容

contents

5.2 经典卷积神经网络的结构

5.2.1 卷积神经网络的发展过程

神经网络的出现可以追溯到 1943 年。当年，心理学家 Warren McCulloch 和数理逻辑学 家 Walter Pitts 首先提出了人工神经网络的概念，并给出了人工神经元的数学模型，从此掀 开了人工神经网络研究的时代。1957 年，美国神经学家 Frank Rosenblatt 成功地在 IBM704 机上完成了感知机的仿真，并于 1960 年实现了手写英文字母的识别。1974 年，Paul Werbos 在其博士论文中首次提出后向传播(Back propagation, BP)思想来修正网络参数的方法，这是 BP 算法的雏形。但在当时由于人工智能正处于发展的低谷，这项工作并没有引起足够的重视。

1986 年，在 Meclelland 和 Rumelhart 等人的努力下，BP 算法被进一步发展，并逐步引起广泛关注，被大量应用于神经网络训练任务当中。BP 算法的主要贡献在于，提出一种基于梯度信息的参数修正算法，为神经网络的训练提供了一种非常成功的参数训练方法。

5.2 经典卷积神经网络的结构

5.2.1 卷积神经网络的发展过程

- 最早的卷积神经网络是由 LannYeCun 等人于 1998 年提出来的，这就是 LeNet。LeNet 主要用于识别手写数字图像，由两个卷积层和两个池化层组成，结构比较简单，但它是最早 达到实用水平的神经网络。

- 真正掀起深度学习风暴的是 LeNet 的加宽版——AlexNet。AlexNet 是于 2012 年由 Hinton 的学生 Krizhevsky Alex 提出来，并在当年ImageNet 视觉挑战赛（ImageNet Large Scale Visual Recognition Challenge, ILSVRC）上以巨大的优势获得冠军。相比于以往战绩，AlexNet 大幅度地降低了图像识别错误率，**它的出现标志着深度学习时代的来临**。

5.2 经典卷积神经网络的结构

5.2.1 卷积神经网络的发展过程

- 2014 年，GoogLeNet 和 VGG 同时诞生。GoogLeNet 是当年的 ILSVRC 冠军，通过设计和开发 Inception 模块，使得模型的参数大幅度减少。VGG 则继续加深网络，通过扩展网络的深度来获取性能的提升。

- 2015 年，残差神经网络 ResNet 诞生，并在当年获得 ILSVRC 冠军。ResNet 旨在解决网 络因深度增加而出现性能退化的问题，它提供了一种构造大深度卷积网络的技术和方法。

- 2019 年，Google 公司开发了一种以效率著称的深度神经网络——EfficientNet。 EfficientNet 仍然是至今为止最好的图像识别网络之一。

5.2 经典卷积神经网络的结构

5.2.2 AlexNet 网络

在结构上，AlexNet 要比 LeNe 复杂得多，它由 5 个卷积层、3 个最大池化层、2 个归一化层和 3 个全连接层组成。

- 在第一层（卷积层 1）中，输入图像的尺寸为 227×227×3，采用 11×11 卷积核，设置的输出通道数为 96、步长为 4，因而在该层输出时，特征图的大小为(227-11)/4+1=55，因此输出特征图的形状为(55×55×96)。

- 在第二层（池化层 1）中，输入的特征图就是上一层的输出，其尺寸为 227×227×3，该层采用 3×3 池化核，步长为 2，因而输出特征图的尺寸为(55-3)/2+1=27，从而该层输出特征图的形状为 27×27×96（池化层不改变通道数）。

5.2 经典卷积神经网络的结构

5.2.2 AlexNet 网络

- 其他层输出的特征图的形状变化可以依次类推，具体操作和输出特征图的形状变化见右表：

网络层	输入形状	操作（等效操作）	输出形状	特征图大小计算依据	当前层中的参数量
卷积层 1	227×227×3	11×11 卷积核，输出通道数为 96，步长为 4	55×55×96	(227-11)/4+1=55	96×3×11×11+96=34944
池化层 1	55×55×96	3×3 池化核，步长为 2	27×27×96	(55-3)/2+1=27	0
归一化层					0
卷积层 2	27×27×96	5×5 卷积核，输出通道数为 256，步长为 1，填充为 2	27×27×256	(27-5+2*2)/1+1=27	256×96×3×3+256=221440
池化层 2	27×27×256	3×3 池化核，步长为 2	13×13×256	(27-3)/2+1=27	0
归一化层					0
卷积层 3	13×13×256	3×3 卷积核，输出通道数为 384，步长为 1，填充为 1	13×13×384	(13-3+2*1)/1+1=13	384×256×3×3+384=885120
卷积层 4	13×13×384	出通道数为 384，步长为 1，填充为 1	13×13×384	(13-3+2*1)/1+1=13	384×384×3×3+384=1327488
卷积层 5	13×13×384	3×3 卷积核，输出通道数为 256，步长为 1，填充为 1	13×13×256	(13-3+2*1)/1+1=13	256×384×3×3+256=884992
池化层 3	13×13×256	3×3 池化核，步长为 2	6×6×256	(13-3)/2+1=6	0
扁平化	6×6×256	将特征图向量化	9216		0
全连接层 1	9216	全连接	4096		9216×4096+4096=37752832
全连接层 2	4096	全连接	4096		4096×4096+4096=16781312
全连接层 3	4096	全连接	1000		4096×1000+1000=4097000

5.2 经典卷积神经网络的结构

5.2.3 VGGNET 网络

VGGNet 是牛津大学 Simonyan 等人提出的一种深度神经网络结构，其中比较常用的结 构是 VGG16，其次是 VGG19。

VGG16 有十余个网络层，其中有 13 个卷积层和 3 个全连接层，这些都是带有待优化参 数的网络层，一共 16 个网络，因而称为 VGG16。VGG16 网络的层次结构见教材P126：表 5-2 VGG16 网络的层次结构。

从表 5-2 中可以看出，VGG16 全部采用 3×3 卷积核（步长均为 1）和 2×2 池化核（步长均为 2），在卷积时均填充数为 1（即填充 1 个 0 圈）。

AlexNet 采用大的卷积核，以扩大其感受野，因此层次不需要很高。与 AlexNet 相比，VGG16 采用小卷积核和小池化核，各层的参数不多，但堆叠了 13 层 3×3 卷积核。底层卷积核的感受野确实不大，但高层的感受野同样很大，而且层与层之间的非线性映射可以提高对底层特征学习的抽象能力。

5.2 经典卷积神经网络的结构

5.2.3 VGGNET 网络

VGG16 是如何把不同尺寸的特征图都转化为最后一维的大小为 25088 的张量呢？这主 要依赖于第 33 行所示的自适应平均池化层。该层对应的代码如下：

```
nn.AdaptiveAvgPool2d(output_size=(7, 7))
```

其作用是，对输入该层的特征图，不管图像尺寸为多少，其输出特征图的尺寸永远为 7×7（批量大小和通道数不变，通道数为 512）。这样，经过扁平化后得到输入全连接网络层的维度大小为 7×7×512 = 25088。也就是说，自适应平均池化层保证了 VGG16 可以接受不同尺寸图像的输入，而不需改变网络的结构。

5.2 经典卷积神经网络的结构

5.2.4 GoogLeNet 网络与 1×1 卷积核

GoogLeNet 使用了许多关键技术，其中很重要的技术就是设计了 1×1 卷积核。下面先看看 1×1 卷积核的作用。
从 nn.Conv2d()函数看，1×1 卷积核对应的函数如下：w-1+1=w

```
nn.Conv2d(in_channels, out_channels, (1, 1))
```

其中，默认步长为 1，无填充

GoogLeNet 这个名字可以理解为 Google+LeNet，意指是 Google 公司在 LeNet 的基础上发展出来的。GoogLeNet 有两个特点，一个是 GoogLeNet 有九个称为 Inception 的模块构成，另一个是有三个 softmax 输出层。

5.2 经典卷积神经网络的结构

5.2.4 GoogLeNet 网络与 1×1 卷积核

Inception 模块经过了几个版本演进，分别是原始版本、v1、v2 和 v3。Inception 原始版本和 Inception v1 的结构分别如图 下图(a)和(b)所示。

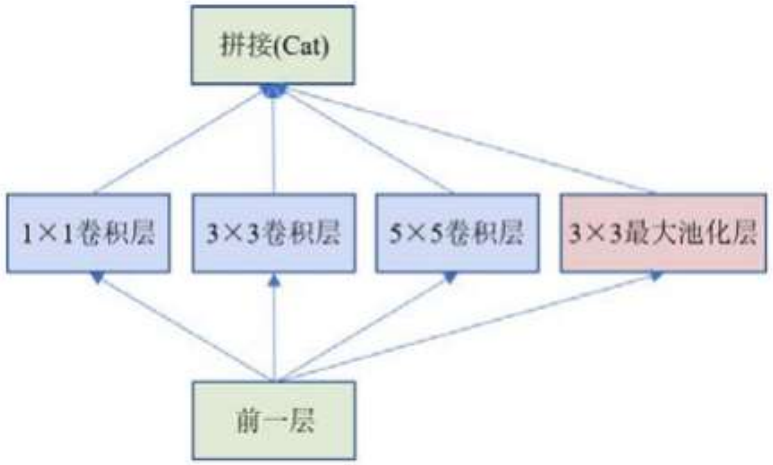

（a）Inception 的初始版本

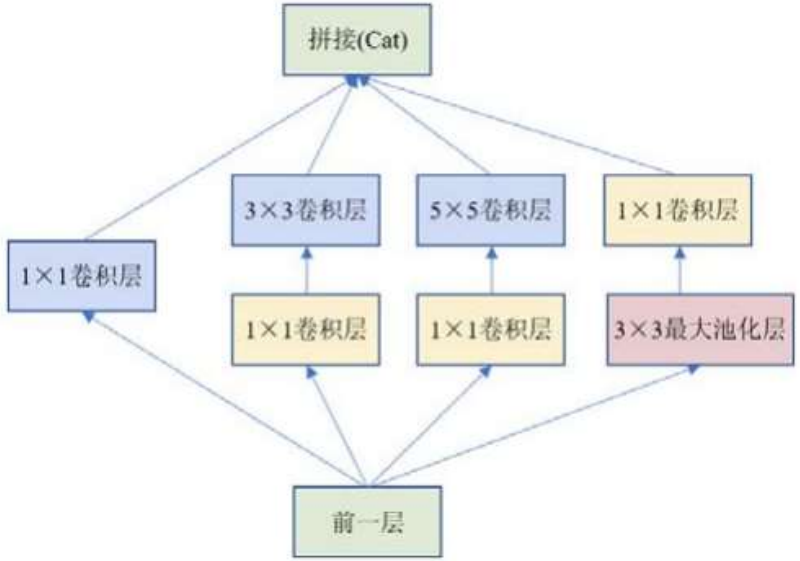

（b）Inception v1（改进版本）

5.2 经典卷积神经网络的结构

5.2.5 ResNet 网络

残差网络：由多个残差模块组成，右图是一个残差模块的结构。

一个残差模块包含两个 3×3 卷积层，其中步长 1，填充为 1，所以这两个卷积层都不会改变特征图的尺寸。

输入 X 在通过第一个卷积层后，经过一个 relu 激活函数，再进入第二个同样的卷积层，形成输出 F(X)，接着 F(X)再与恒等映射过来的 X 按位相加，最后再经过一个 relu 激活函数后作为残差模块的输出。

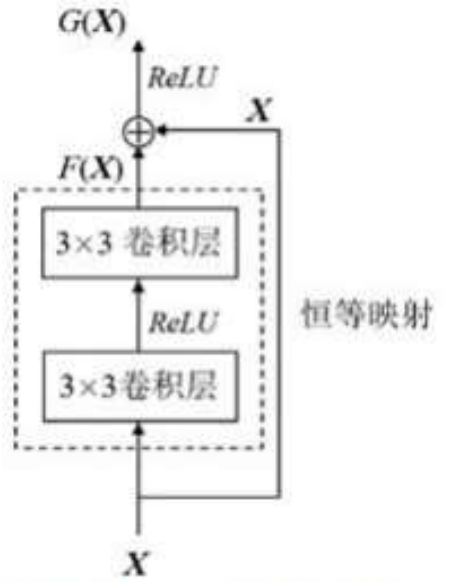

图 5-3　一个残差模块

5.2 经典卷积神经网络的结构

5.2.5 ResNet 网络

令 G(X)表示残差模块的输出，则有：

$$G(X) = F(X) + X$$

由上式也可以得到，F(X) = G(X) – X。也就是说，可以把两个卷积层的输出 F(X)看成是 G(X)和 X 之间的误差估计，其中 X 是输入的数据张量，没有学习参数，F(X)看成是两个卷积层构成的子网，有学习参数。通过对 F(X)中参数的学习，使得在使用误差 F(X)修正 X 后，修正的结果 F(X) + X 更接近 G(X)。

5.2 经典卷积神经网络的结构

5.2.5 ResNet 网络

由多个残差模块堆叠而形成的**残差网络（ResNet）**的架构可用右图表示。

- 一个方框表示一个网络层；
- 一条弧线表示一个恒等映射；
- 虚线画的弧线表示需要对特征图做一些变换，如调整特征图的尺寸和通道数等，以保证 F(X)和 X 能够按位相加；
- 一条弧线及其跨越的两个表示卷积层的方框，共同构成了一个残差模块。

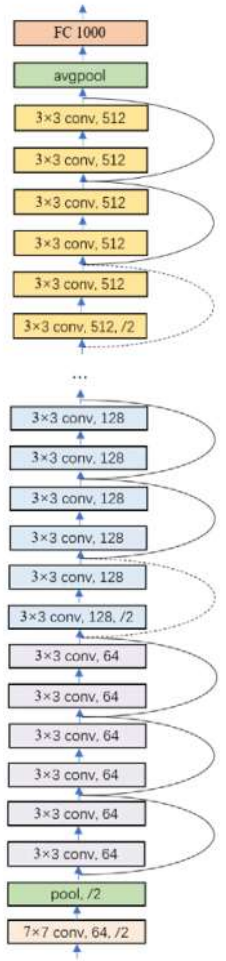

5.2 经典卷积神经网络的结构

5.2.5 EfficientNet 网络

提高神经网络对图像的处理能力，通过三种途径来实现：

1. 增加网络的**宽度**：实际上就是增加每个网络层上卷积核的个数，以提取更多的特征，其原理如图 5-5(b)所示；

2. 增加网络的**深度**：即增加网络的层数，提高卷积核的感受野及其提取抽象特征的能力，如 VGG、ResNet 等，如图 5-5(c)所示；

3. 增加图像的**分辨率**：提高图像本身蕴含的信息量，如图 5-5(d)所示。

5.2 经典卷积神经网络的结构

5.2.5 EfficientNet 网络

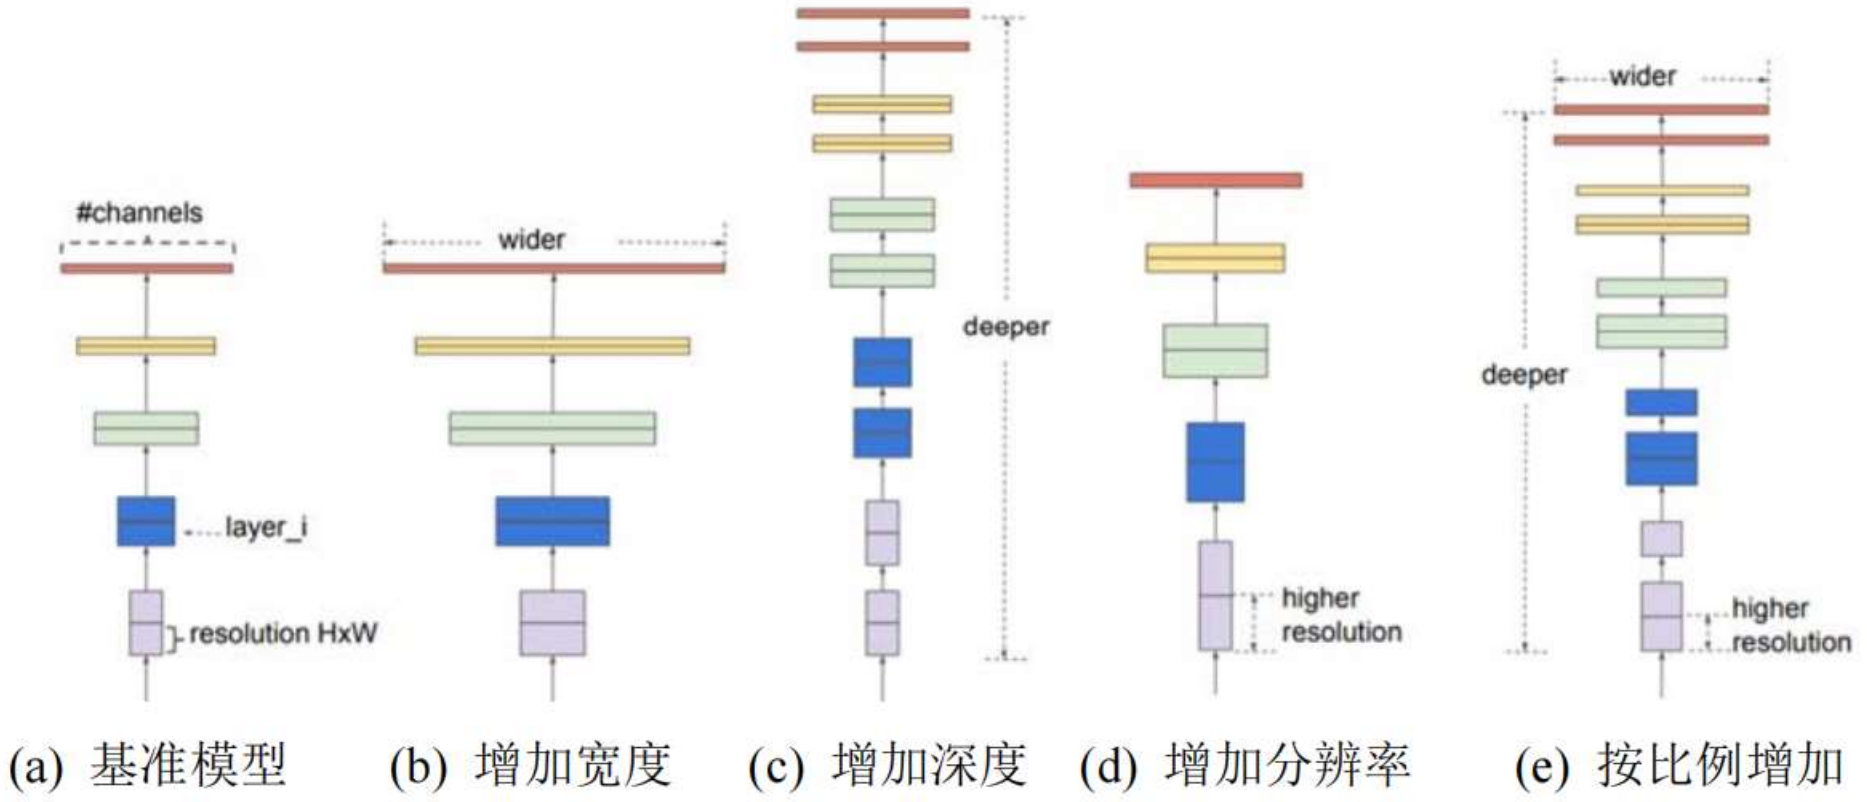

(a) 基准模型　(b) 增加宽度　(c) 增加深度　(d) 增加分辨率　(e) 按比例增加

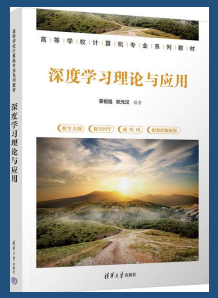

本 章 内 容

contents

5.3 预训练模型的迁移方法

5.3.1 预训练网络迁移的基本原理

迁移学习（Transfer learning）引入：

假设在一个样本足够多的数据集（源数据集）上训练（预训练）出一个好的模型（源模型，对下游任务而言称为预训练模型），能够完美地解决给定的任务（源任务）。此后，将源模型中全部或部分网络层及其参数迁移过来，并在适当添加新网络层的基础上重新构造一个新模型（目标模型），然后在一个数据量较少的数据集（目标数据集）上进行训练，以用于解决新的任务（目标任务）。在这个训练过程中，源模型中迁移过来的参数一般不参与训练（被冻结了），而只是训练因新增加网络层而产生的少量参数。

5.3 预训练模型的迁移方法

5.3.1 预训练网络迁移的基本原理

在迁移方法当中，**微调（fine tuning）**是常采用的一种迁移方法。微调一般是指通过调 整分类网络最后一个输出层的来构建新网络的方法（而其他网络层全部复制过来）。当然，由于这种调整而产生的新参数是需要重新训练的，而其他参数不需要重新训练。

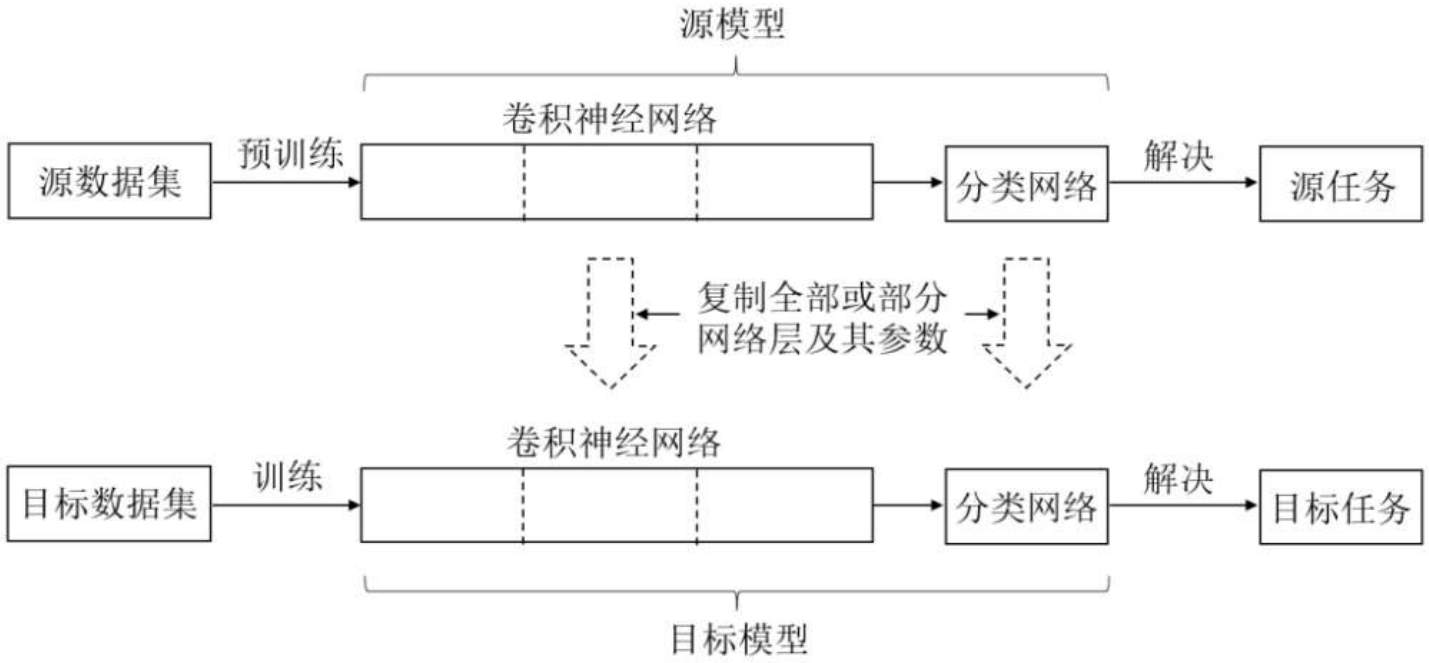

5.3 预训练模型的迁移方法

5.3.2 VGG16 的迁移案例

【例 5.2】从 VGG16 迁移出若干个网络层来构建新的网络。

假设需要对 224*224 的灰度图像进行二分类，要求使用 VGG16 中第 3、第 5 和第 31 行，见下面代码所示的卷积层。

```
vgg16 = models.vgg16(pretrained=True).to(device)
conv1 = nn.Conv2d(1, 3, 3) #(1, 3)，新定义
conv2 = vgg16.features[0] #(3, 64)，来自 VGG16，参数需要冻结
conv3 = vgg16.features[2] #(64, 64)，来自 VGG16，参数需要冻结
conv4 = nn.Conv2d(64, 512, 3) #(64, 512)，新定义
conv5 = vgg16.features[28] #(512, 512)，来自 VGG16，参数需要冻结
```

5.3 预训练模型的迁移方法

5.3.2 VGG16 的迁移案例

然后冻结来自 VGG16 的网络层的参数:

```
L = [conv2,conv3,conv5] #对这些网络层上的参数进行冻结
    for layer in L:
        for param in layer.parameters():
            param.requires_grad = False
```

接着定义全连接网络层，构造分类网络:

```
self.fc1 = nn.Linear(512*6*6, 2048)
self.fc2 = nn.Linear(2048, 1024)
self.fc3 = nn.Linear(1024, 2)
```

5.3 预训练模型的迁移方法

5.3.2 VGG16 的迁移案例

最后编写测试代码和参数统计代码，核心代码如下：

```
import torch
import torch.nn as nn
from torchvision import models
device = torch.device("cuda" if torch.cuda.is_available() else "cpu")
vgg16 = models.vgg16(pretrained=True).to(device)
conv1 = nn.Conv2d(1, 3, 3) #(1, 3), 新定义
conv2 = vgg16.features[0] #(3, 64), 来自 VGG16, 参数需要冻结
conv3 = vgg16.features[2] #(64, 64), 来自 VGG16, 参数需要冻结
conv4 = nn.Conv2d(64, 512, 3) #(64, 512), 新定义
conv5 = vgg16.features[28] #(512, 512), 来自 VGG16, 参数需要冻结
L = [conv2,conv3,conv5] #对这些网络层上的参数进行冻结
for layer in L:
    for param in layer.parameters():
        param.requires_grad = False
```

该程序的核心代码（全部代码见教材P134）

5.3 预训练模型的迁移方法

5.3.2 VGG16 的迁移案例

执行上述代码，输入结果如下：

```
    该模型的参数总数为：42544992，其中可训练的参数总数为：40146464，占的百分比为：
94.36%
    输入和输出的形状分别为：  torch.Size([16, 1, 224, 224]) torch.Size([16, 2])
```

从这个例子中，读者不难举一反三，总结从 VGG16 中迁移任意若干个网络层来构造新网络的方法。

5.3 预训练模型的迁移方法

5.3.3 预训练网络迁移的基本原理

【例 5.3】GoogLeNet 的迁移案例。

该例使用已训练好的 GoogLeNet 模型来对数据集 flower_photos 进行分类。该数据集经 常用于图像分类教学，下载自 http://download.tensorflow.org/example_images/flower_photos.tgz。 下载并解压后，产生五个目录，保存于./data/flower_photos 目录下，

图 5-7 数据集 flower_photos 的目录结构

如右图所示。这五个目录名分别表示雏菊花、蒲公英、玫瑰花、葵花和郁金香五种花。这些花的图像文件分别保存在相应的目录下，文件数量分别为 633、898、641、699 和 799，总数为 3670。

5.3 预训练模型的迁移方法

5.3.3 预训练网络迁移的基本原理

该程序的代码编写步骤如下。

（1）编写加载数据及打包数据的代码基本思路：

① 先定义函数 getFileLabel(tmp_path)，其作用是：读取每个文件的相对路径（含文件名）及其类别（分别用 0、1、2、3、4 对类别 编号），形成以二元组(路径, 类别编号)为元素的列表。

② 然后，划分训练集和测试集，并通过 定义数据集类 FlowerDataSet(Dataset)，以训练集和测试集作为输入，将它们分别映射为该类 的实例 train_dataset 和 test_dataset。

③ 最后，用 DataLoader()类对 train_dataset 和 test_dataset 进行打包，形成两个实例 train_loader 和 test_loader。具体代码见随后列出的程序代码。

5.3 预训练模型的迁移方法

5.3.3 预训练网络迁移的基本原理

（2）用下列语句下载已训练好的 GoogLenet 模型：

```
googlenet_base = models.googlenet(num_classes=5, init_weights=True)
```

其中，num_classes=5 表示模型的类别个数为 5。显然，num_classes=1000 表示下载模型的类别为 1000。init_weights=True 表示同时下载参数，否则模型将随机初始化参数。该模型比较大，建议先 torch.save()函数将模型保存到磁盘，以后调试时利用 torch.load()函数从磁盘 中加载模型，否则每次调试都花费时间等待。

5.3 预训练模型的迁移方法

5.3.3 预训练网络迁移的基本原理

（3）更新模型 googlenet_base 的参数。为此，先从下列地址下载模型的参数文件：https://download.pytorch.org/models/googlenet-1378be20.pth。该参数文件保存了至目前为止最好的参数（比初始参数要好得多），因此最好用该文件中的参数更新上面下载的模型的参数。但该文件默认适用于类别为 1000 的模型，而上面下载的模型的类别为 5。我们先 print(googlenet_base)语句查看该模型的层次结构，结果如右。

```
  (aux1): InceptionAux(
    (conv): BasicConv2d(
      (conv): Conv2d(512, 128, kernel_size=(1, 1), stride=(1, 1), bias=False)
      (bn): BatchNorm2d(128, eps=0.001, momentum=0.1, affine=True, track_running_stats=True)
    )
    (fc1): Linear(in_features=2048, out_features=1024, bias=True)
    (fc2): Linear(in_features=1024, out_features=5, bias=True)
  )
  (aux2): InceptionAux(
    (conv): BasicConv2d(
      (conv): Conv2d(528, 128, kernel_size=(1, 1), stride=(1, 1), bias=False)
      (bn): BatchNorm2d(128, eps=0.001, momentum=0.1, affine=True, track_running_stats=True)
    )
    (fc1): Linear(in_features=2048, out_features=1024, bias=True)
    (fc2): Linear(in_features=1024, out_features=5, bias=True)
  )
  (avgpool): AdaptiveAvgPool2d(output_size=(1, 1))
  (dropout): Dropout(p=0.2, inplace=False)
  (fc): Linear(in_features=1024, out_features=5, bias=True)
)
```

5.3 预训练模型的迁移方法

5.3.3 预训练网络迁移的基本原理

下划线的三行代码都是表示输出类别为 5 的全连接输出层，它们的结构跟参数文件 googlenet-1378be20.pth 的结构不匹配，因此该参数文件不能更新这个全连接层。所以，我们用该参数文件更新这三个全连接层以外的其他网络层的参数，代码如下：

```
model_dict = googlenet_base.state_dict()
#从磁盘加载最新的参数文件
pretrain_model = torch.load(f"./pre_models/googlenet-1378be20.pth")
#googlenet-1378be20.pth 类别数量为 1000,此处为 5,故不能更新这几个网络层的参数
del_list = ["aux1.fc2.weight", "aux1.fc2.bias",
            "aux2.fc2.weight", "aux2.fc2.bias",
            "fc.weight", "fc.bias"] #不能被更新的参数
pretrain_dict = {k: v for k, v in pretrain_model.items() if k not in del_list}
#用 googlenet-1378be20.pth 中的参数值更新模型参数
googlenet_base model_dict.update(pretrain_dict)
```

5.3 预训练模型的迁移方法

5.3.3 预训练网络迁移的基本原理

（4）冻结部分网络层的参数。为此，先冻结所有的参数：

```
for param in googlenet_base.parameters(): #先冻结所有的参数
    param.requires_grad = False
```

然后解冻五个全连接层的参数，表示这些参数是待学习参数：

```
layers = [ googlenet_base.aux1.fc1, googlenet_base.aux1.fc2,
googlenet_base.aux2.fc1, googlenet_base.aux2.fc2,
googlenet_base.fc]
for layer in layers:
    for param in layer.parameters():
        param.requires_grad = True
```

5.3 预训练模型的迁移方法

5.3.3 预训练网络迁移的基本原理

模型训练和测试的代码：

在训练模式下，调用模型后返回值的类型是 torchvision.models.googlenet.GoogLeNetOutputs，不是张量，因 此需要用 logits 属性获得返回值的张量，相应代码如下：

```
pre_y = googlenet_model(x)
pre_y = pre_y.logits
```

而在测试模式下（googlenet_model.eval()），googlenet_model(x)返回的是张量，就不能用第二条语句了。

该程序的部分代码如下：

5.3 预训练模型的迁移方法

5.3.3 预训练网络迁移的基本原理

```
#下载模型需要时间，笔者已经将模型下载并放在指定的目录（./pre_models）了
googlenet_base = models.googlenet(num_classes=5,init_weights=True)
torch.save(googlenet_base,'./pre_models/googlenet_base5')
'''
#加载已下载的模型，类别个数为 5
googlenet_base = torch.load('./pre_models/googlenet_base5')
model_dict = googlenet_base.state_dict()
#加载最新的模型参数
pretrain_model = torch.load(f"./pre_models/googlenet-1378be20.pth")
#googlenet-1378be20.pth 对应类别数量为 1000，此处为 5，
#故不能更新这几个网络层的参数
del_list = ["aux1.fc2.weight", "aux1.fc2.bias",
            "aux2.fc2.weight", "aux2.fc2.bias",
            "fc.weight", "fc.bias"]
pretrain_dict = {k: v for k, v in pretrain_model.items() if k not in del_list}
#用 googlenet-1378be20 中的参数值更新模型 googlenet_base
model_dict.update(pretrain_dict)
googlenet_base.load_state_dict(model_dict)
#----------------
#先冻结所有的参数
for param in googlenet_base.parameters():
    param.requires_grad = False
#再解冻五个全连接层的参数：
layers = [googlenet_base.aux1.fc1, googlenet_base.aux1.fc2,
googlenet_base.aux2.fc1, googlenet_base.aux2.fc2,
googlenet_base.fc]
for layer in layers:
    for param in layer.parameters():
        param.requires_grad = True
googlenet_model = googlenet_base.to(device)
optimizer = optim.Adam(googlenet_model.parameters())
```

该程序的核心代码（全部代码见教材P138）

5.3 预训练模型的迁移方法

5.3.3 预训练网络迁移的基本原理

执行上述代码，结果如下（部分）：

```
… …
9 0.4279835522174835
9 0.22218433022499084
运行时间：  1.9098375598589579  分钟
在测试集上的准确率：  0.8746594190597534
```

该结果表示，只在运行 10 代的情况下，即可达到 0.87 的准确率。这说明，上述迁移方法对此类数据集是相对有效的。

5.3 预训练模型的迁移方法

5.3.4 ResNet 的迁移案例

【例 5.4】ResNet 的迁移案例：

加载预训练模型 ResNet50 的代码如下：

```
resnet50 =
models.resnet50(pretrained=True)
```

但我们目前不知道该模型长成什么样子，不知从何入手对其结构进行更改。为此，一般的做法是打印该模型的层次结构（print(resnet50)），结果如右图所示。

```
    (2): Bottleneck(
      (conv1): Conv2d(2048, 512, kernel_size=(1, 1), stride=(1, 1), bias=False)
      (bn1): BatchNorm2d(512, eps=1e-05, momentum=0.1, affine=True, track_running_stats=True)
      (conv2): Conv2d(512, 512, kernel_size=(3, 3), stride=(1, 1), padding=(1, 1), bias=False)
      (bn2): BatchNorm2d(512, eps=1e-05, momentum=0.1, affine=True, track_running_stats=True)
      (conv3): Conv2d(512, 2048, kernel_size=(1, 1), stride=(1, 1), bias=False)
      (bn3): BatchNorm2d(2048, eps=1e-05, momentum=0.1, affine=True, track_running_stats=True)
      (relu): ReLU(inplace=True)
    )
  )
  (avgpool): AdaptiveAvgPool2d(output_size=(1, 1))
  (fc): Linear(in_features=2048, out_features=5, bias=True)
)
```

5.3 预训练模型的迁移方法

5.3.4 ResNet 的迁移案例

从上图中可以看出，最后一层是全连接层，我们可以对该层进行微调（当然，也可以对其他有关的网络层进行修改，但一般不建议这么做），并冻结除了该层以外的其他层参数，代码如下：

```
resnet50.fc = nn.Linear(2048, 5) #改为最后一层有 5 个输出节点， 因为是 5 分类
for param in resnet50.parameters(): #先冻结全部参数
    param.requires_grad = False
for param in resnet50.fc.parameters(): #在解冻最后一层的参数
    param.requires_grad = True
```

5.3 预训练模型的迁移方法

5.3.4 ResNet 的迁移案例

模型创建和调整已经完成。此后，训练和测试的代码跟例 5.3 相似。程序核心代码如右边所示：

```
#给定数据集，测试在其上的准确率：
def getAccOnadataset(data_loader):
        resnet50.eval()
        correct = 0
        with torch.no_grad():
                for i, (x, y) in enumerate(data_loader):
                        x, y = x.to(device), y.to(device)
                        pre_y = resnet50(x)
                        pre_y = torch.argmax(pre_y, dim=1)
                        t = (pre_y == y).long().sum()
                        correct += t
                correct = 1. * correct / len(data_loader.dataset)
                resnet50.train()
return correct.item()
start=time.time() #开始计时
resnet50.train()
```

该程序的核心代码（全部代码见教材P141）

5.3 预训练模型的迁移方法

5.3.4 ResNet 的迁移案例

运行该程序，输入结果如下：

```
… …
9 0.26216524839401245
9 0.057888846844434 74
运行时间： 2.4728100061416627 分钟
在测试集上的准确率： 0.893733024597168
```

可见，该程序获得 0.89 的准确率，相对比较高。这说明，该迁移方法对此类数据集是比较有效的。

5.3 预训练模型的迁移方法

5.3.5 EfficientNet 的迁移案例

【例 5.5】EfficientNet 的迁移案例：

该例子使用 EfficientNet 作为预训练模型，解决的问题也跟例 5.3 一样，都是对数据集 flower_photos 进行分类。类似地，其加载和打包数据的代码也跟例 5.3 完全一样，故在此不做介绍。

导入 EfficientNet-B7，这是一种非常优秀的 EfficientNet 网络模型：

```
from efficientnet_pytorch import EfficientNet
effi_model = EfficientNet.from_pretrained('efficientnet-b7').to(device)
```

注意，系统提示可以导入 EfficientNet 网络模型包括：efficientnet-b0, efficientnet-b1, efficientnet-b2, efficientnet-b3, efficientnet-b4, efficientnet-b5, efficientnet-b6, efficientnet-b7, efficientnet-b8, efficientnet-l2，但笔者只成功导入 efficientnet-b7。

5.3 预训练模型的迁移方法

5.3.5 EfficientNet 的迁移案例

为了解模型的结构，用 print(model)打印出它的层次结构，然后查看哪些网络层可以利用和修改。比如，上述导入的模型的层次结构如下图所示。

```
  (_conv_head): Conv2dStaticSamePadding(
    640, 2560, kernel_size=(1, 1), stride=(1, 1), bias=False
    (static_padding): Identity()
  )
  (_bn1): BatchNorm2d(2560, eps=0.001, momentum=0.010000000000000009,
  (_avg_pooling): AdaptiveAvgPool2d(output_size=1)
  (_dropout): Dropout(p=0.5, inplace=False)
  (_fc): Linear(in_features=2560, out_features=1000, bias=True)
  (_swish): MemoryEfficientSwish()
)
```

5.3 预训练模型的迁移方法

5.3.5 EfficientNet 的迁移案例

从上图中可以看出，最后一个全连接层名为“_fc”，其输入节点数为 2560，输出节点数为 1000。

因此，我们可以修改这个网络层，以适合本例 5 分类任务。同时，我们在修改该层网络之后，再增加两个全连接层。程序核心代码如右：

```
model = EfficientNet.from_pretrained('efficientnet-b7').to(device)
for param in model.parameters():
        param.requires_grad = False
feature = model._fc.in_features
model._fc = nn.Linear(in_features=feature,out_features=4096,bias=True) #改变输出层
fc1 = nn.Linear(4096, 2048)
fc2 = nn.Linear(2048, 5)
class EfficientNet(nn.Module):
def __init__(self, model_name='tf_efficientnet_b3_ns', pretrained=True):
        super().__init__()
        self.model = model #利用预训练模型
        self.fc1 = fc1 #增加两个全连接层
        self.fc2 = fc2
def forward(self, x):
        o = x
        o = self.model(o)
        o = nn.ReLU(inplace=True)(o)
        o = nn.Dropout(p=0.5, inplace=False)(o)
        o = self.fc1(o)
        o = nn.ReLU(inplace=True)(o)
        o = nn.Dropout(p=0.5, inplace=False)(o)
        o = self.fc2(o)
        return o
efficient_model = EfficientNet().to(device)
optimizer = optim.Adam(efficient_model.parameters())
```

该程序的核心代码（全部代码见教材P143）

5.3 预训练模型的迁移方法

5.3.5 EfficientNet 的迁移案例

该程序执行了 20 代，输出结果如下：

```
… …
19 0.15419840812683105
19 0.8684183955192566
运行时间：  11.100697712103527 分钟
在测试集上的准确率：  0.856494128704071
```

该程序在测试集上获得的准确率为 0.85，略低于前面两个程序。这也许说明，好的深度模型未必在所有的数据集上都能获得绝对的好结果，这还需要丰富的调参经验为指导。你们不妨试着修改上面的模型，看看怎么改进才能获得更好的结果。

5.5 本章小结

本章内容：

- 几种种经典的卷积神经网络预训练模型
- VGG16, GoogLeNe, ResNet, EfficientNet
- 各个网络的迁移学习